



ULPGC
Universidad de
Las Palmas de
Gran Canaria

IUCES
Instituto Universitario de
Cibernética, Empresa y Sociedad

SEGMENTACIÓN SEMÁNTICA Y SUS APLICACIONES

Fernando Sanfiel Reyes





**Grado en
Ingeniería
Informática**

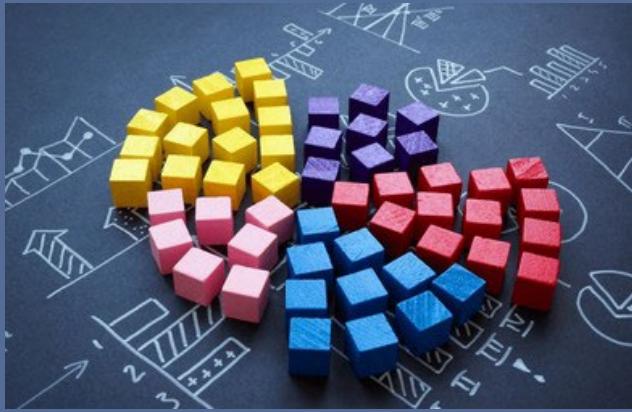
QAISC
Prácticas y TFG

ACTUALIDAD
Investigador y estudiante de
máster

01

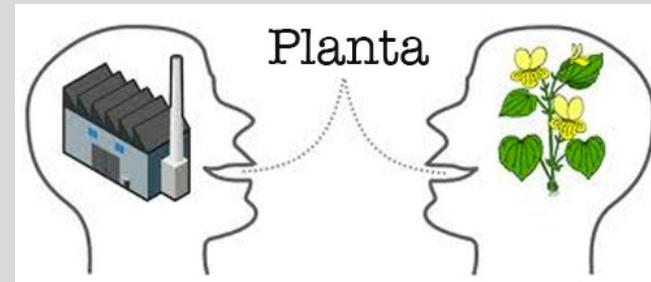
¿Qué es la segmentación semántica?

Segmentación



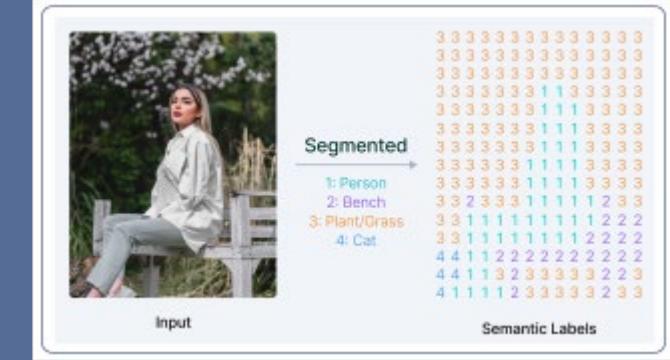
Dividir algo en partes o segmentos

Semántica



Disciplina que estudia el significado de las unidades lingüísticas y de sus combinaciones.

¿Cómo funciona?



Se realiza una clasificación de la imagen a nivel de píxel



Input

Segmented

- 1: Person
2: Bench
3: Plant/Grass
4: Cat

3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	3	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	3	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	1	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	1	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	1	3	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	1	1	3	3	3	3
3	3	3	3	3	3	3	3	3	3	1	1	1	1	1	3	3	3	3
4	4	1	1	2	2	2	2	2	2	2	2	2	2	2	2	2	2	2
4	4	1	1	3	2	3	3	3	3	3	3	2	2	3				
4	1	1	1	1	2	3	3	3	3	3	3	2	3	3				

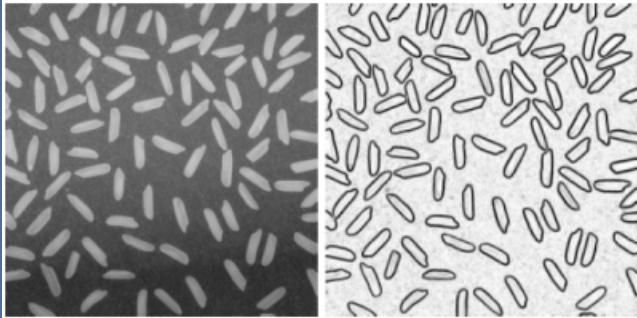
Semantic Labels

02

Métodos de segmentación

Métodos clásicos

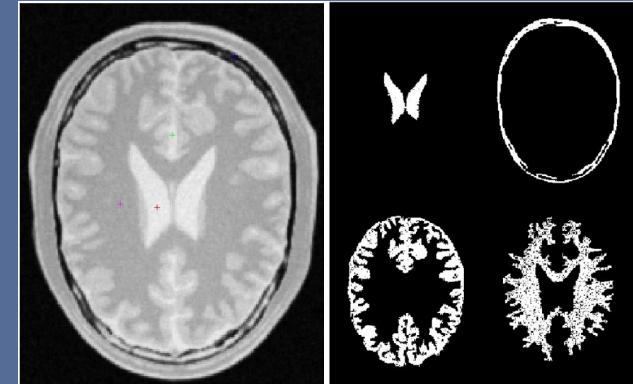
Basado en píxeles



Basado en fronteras

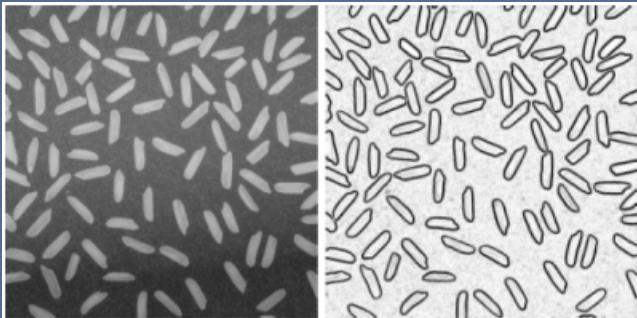


Basado en regiones

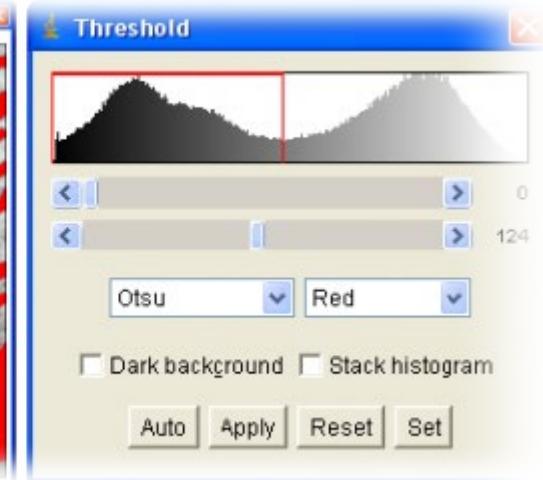
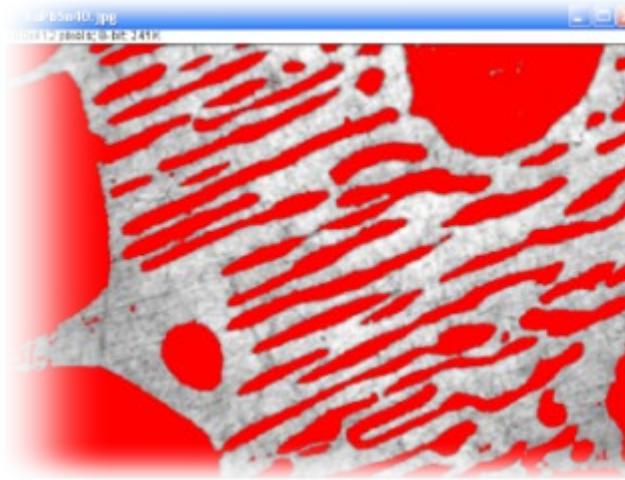


Métodos clásicos

Basado en píxeles



Este método clasifica cada píxel de una imagen según su intensidad, sin considerar su relación con los píxeles vecinos. La estrategia más común es la umbralización



Ventajas

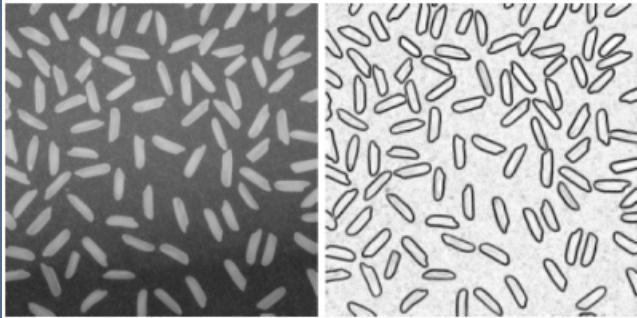
- Rápido y computacionalmente eficiente
- Fácil de implementar

Desventajas

- No funciona bien con imágenes con gradientes de iluminación
- No segmenta estructuras complejas

Métodos clásicos

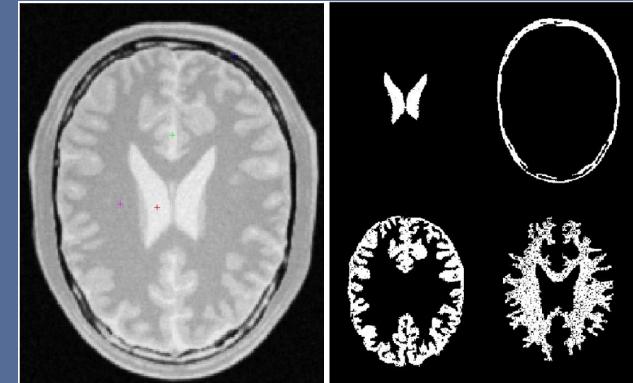
Basado en píxeles



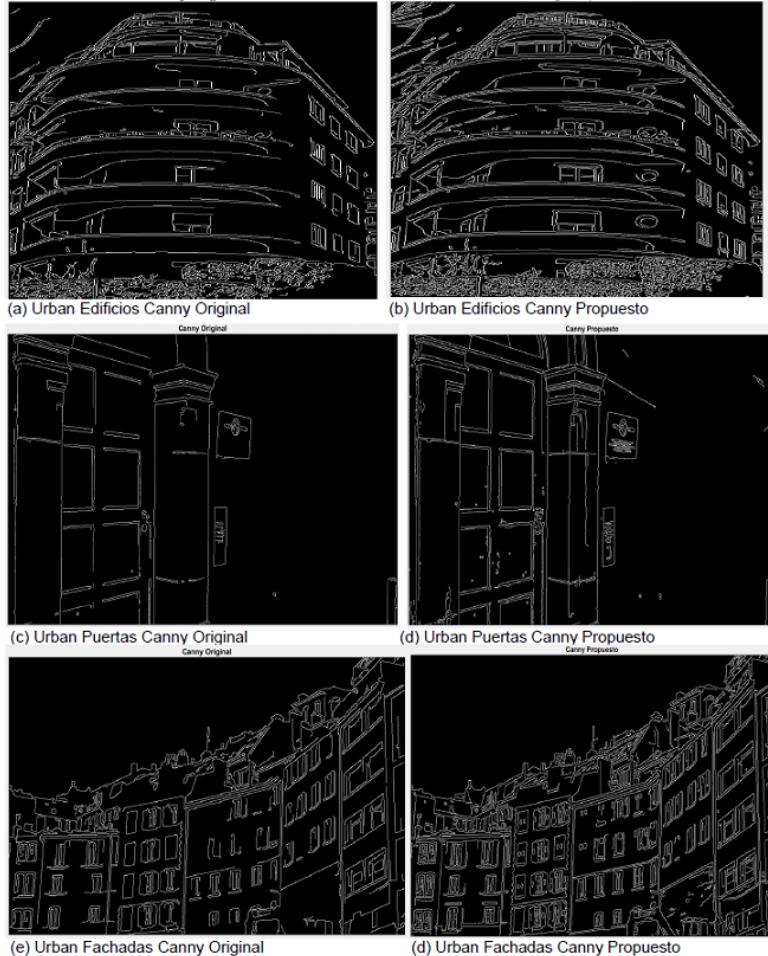
Basado en fronteras



Basado en regiones



Métodos clásicos



Basado en fronteras



Este método detecta cambios bruscos de intensidad para identificar los límites entre objetos

Ventajas

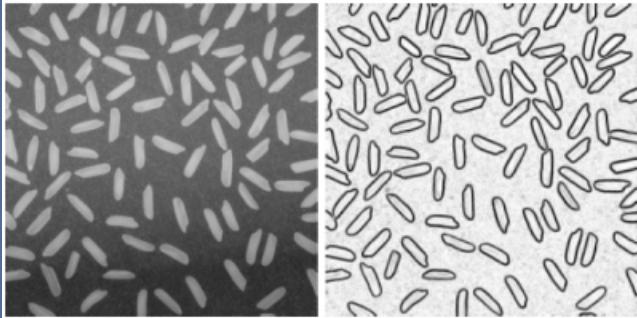
- Permite detectar estructuras bien definidas
- Funciona bien en imágenes con contraste claro

Desventajas

- No segmenta regiones completas, solo los contornos
- Puede generar bordes falsos debido al ruido

Métodos clásicos

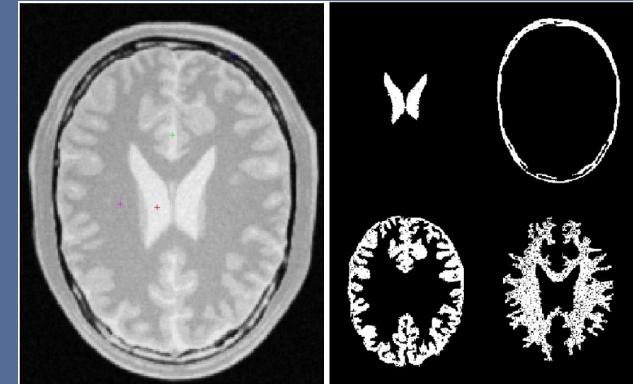
Basado en píxeles



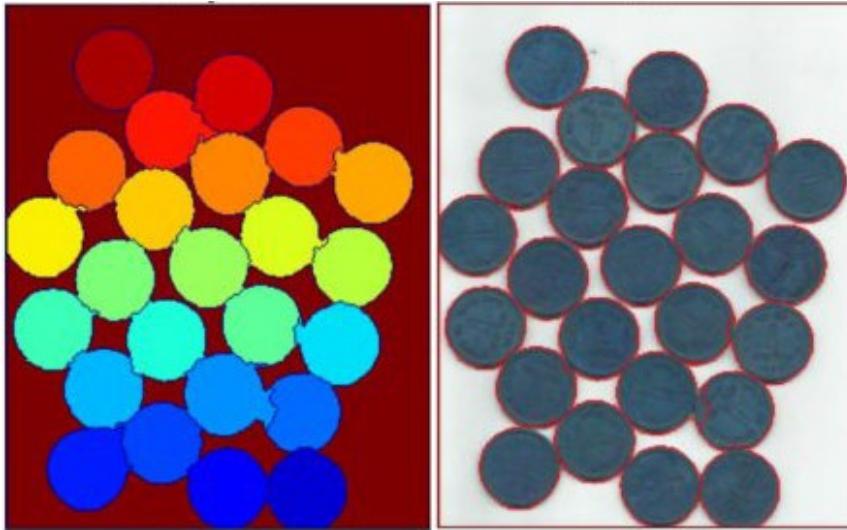
Basado en fronteras



Basado en regiones



Métodos clásicos



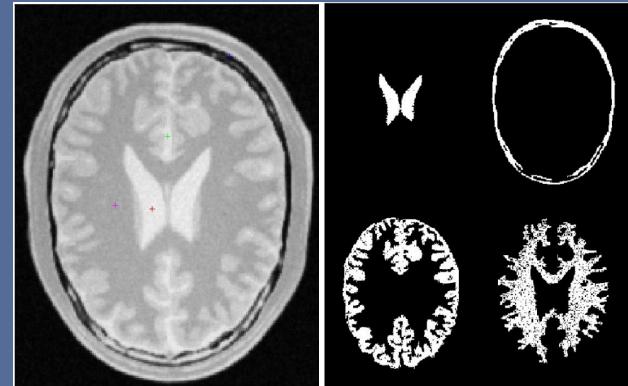
Ventajas

- Segmenta áreas completas en lugar de solo contornos
- Puede combinar múltiples características (color, textura, etc.)

Desventajas

- Puede ser computacionalmente costoso
- No funciona bien cuando las regiones no están claramente separadas

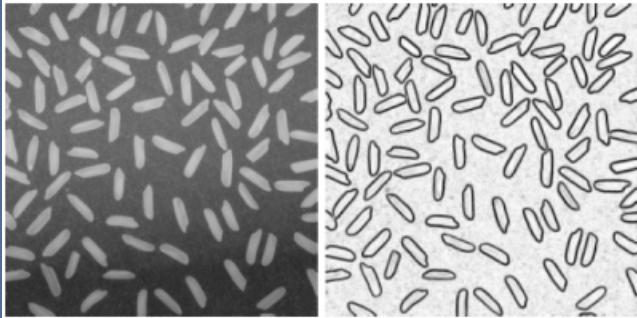
Basado en regiones



Este método agrupa píxeles con propiedades similares, como color, textura o intensidad

Métodos clásicos

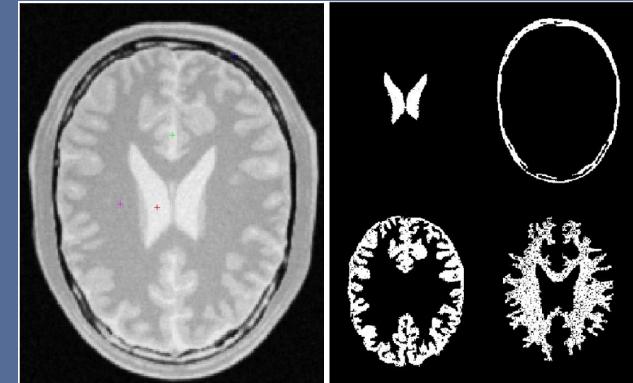
Basado en píxeles



Basado en fronteras

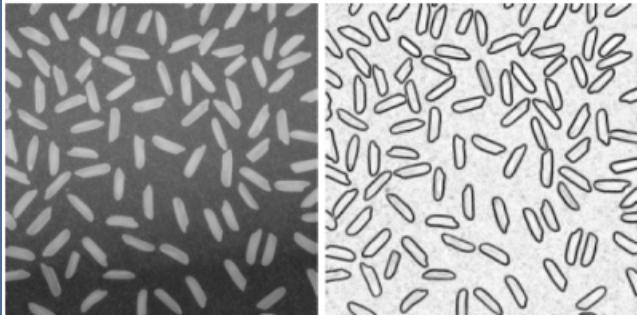


Basado en regiones



Métodos clásicos

Basado en píxeles



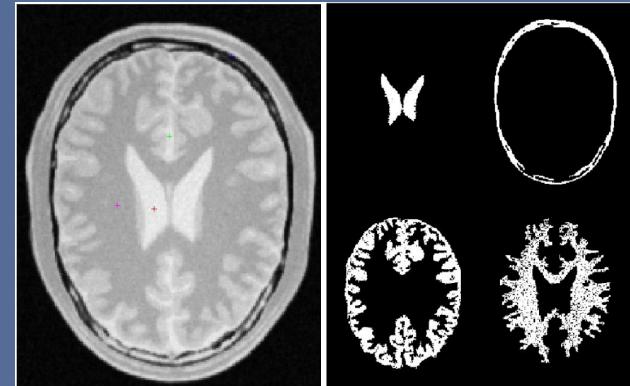
Ideal con imágenes de un alto contraste

Basado en fronteras



Ideal para imágenes con objetos que tengan bordes definidos

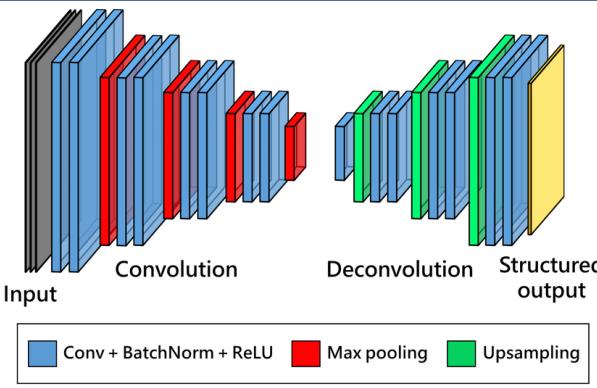
Basado en regiones



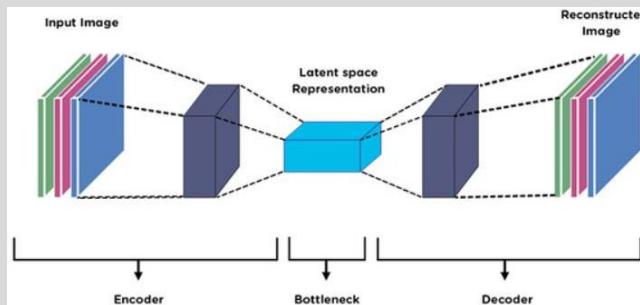
Ideal para realizar segmentación de objetos completos

Deep Learning

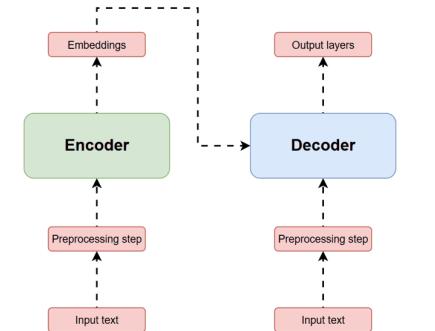
Fully Convolutional



Encoder-Decoder

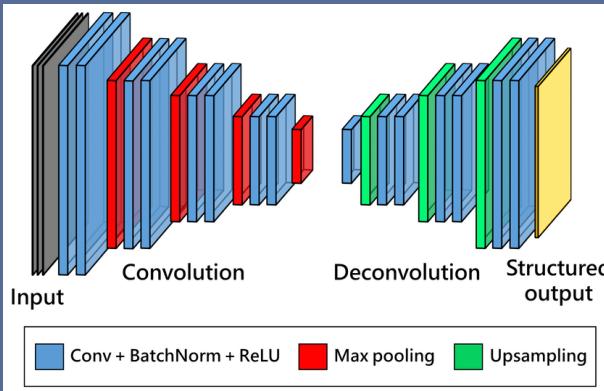


Transformers

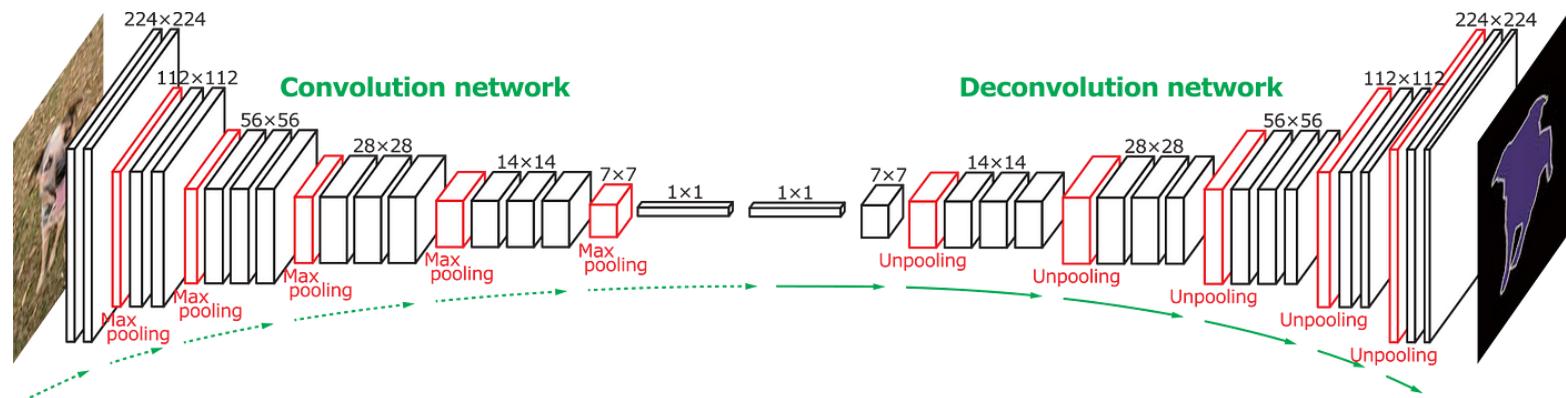


Deep Learning

Fully Convolutional



Modelo creado con capas convolucionales.
Especializadas en el
procesado de imágenes para
segmentación semántica



Ventajas

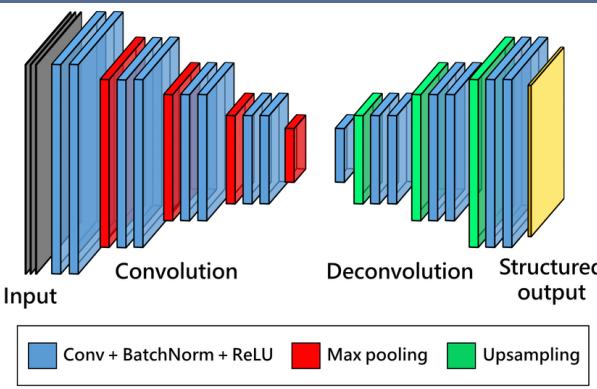
- Son rápidas y eficientes
- Funcionan bien en tareas de segmentación semántica básicas

Desventajas

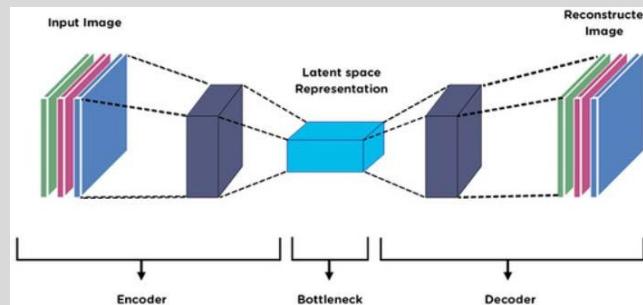
- Pérdida de información espacial debido a la reducción de resolución
- No capturan bien detalles finos en los bordes de los objetos

Deep Learning

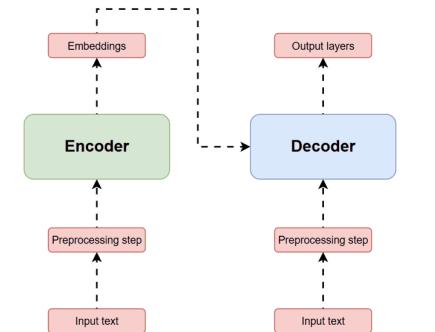
Fully Convolutional



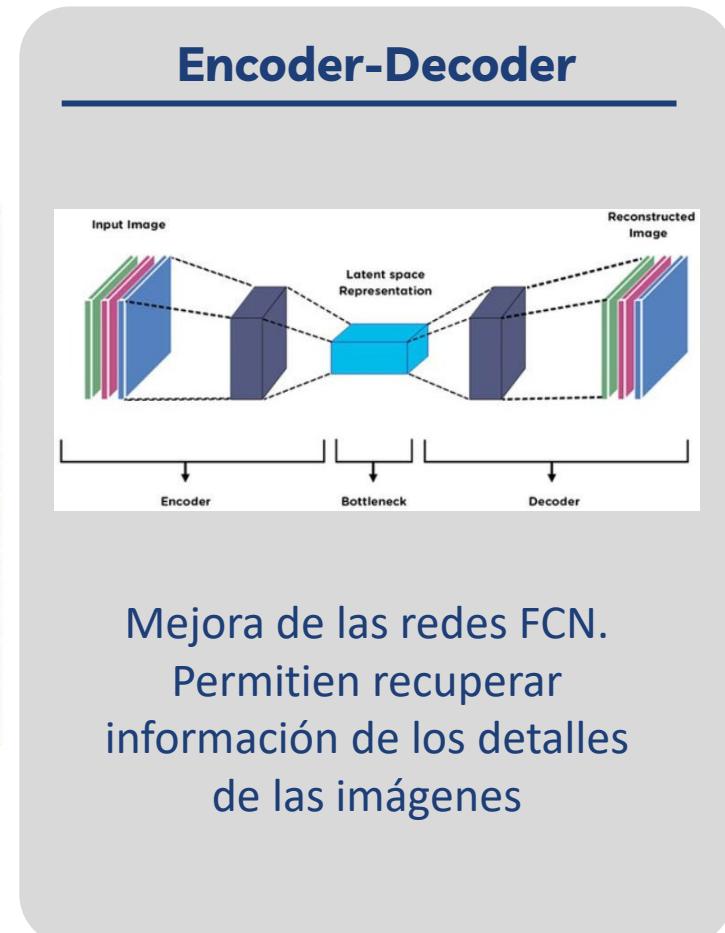
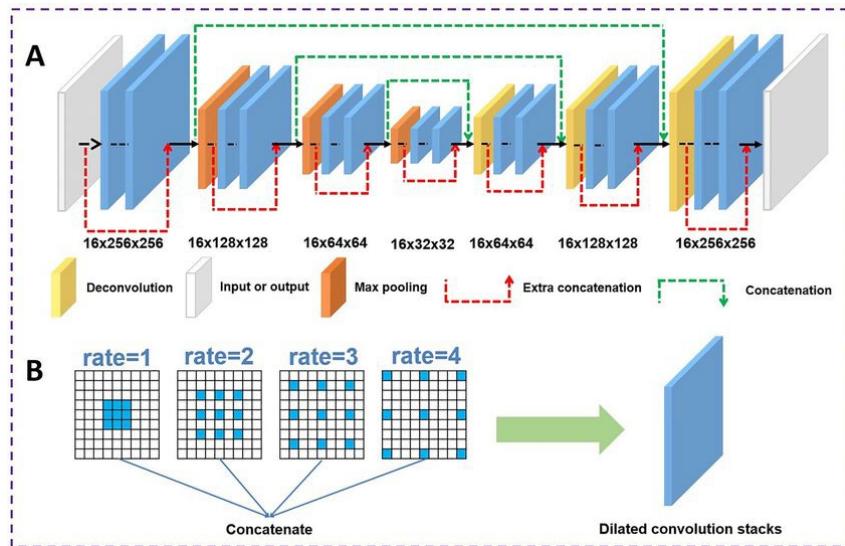
Encoder-Decoder



Transformers



Deep Learning

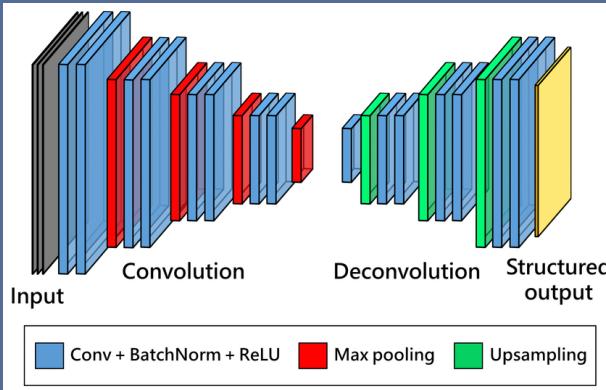


- ✓ Ventajas**
 - Recupera mejor los detalles que una FCN
 - Permite segmentación más precisa en imágenes médicas y con estructuras finas

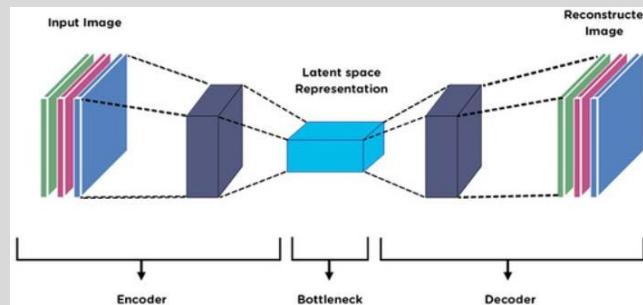
- ✗ Desventajas**
 - Mayor costo computacional que las FCN
 - Puede perder contexto global en imágenes grandes

Deep Learning

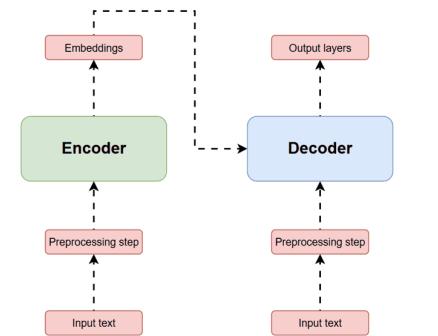
Fully Convolutional



Encoder-Decoder



Transformers

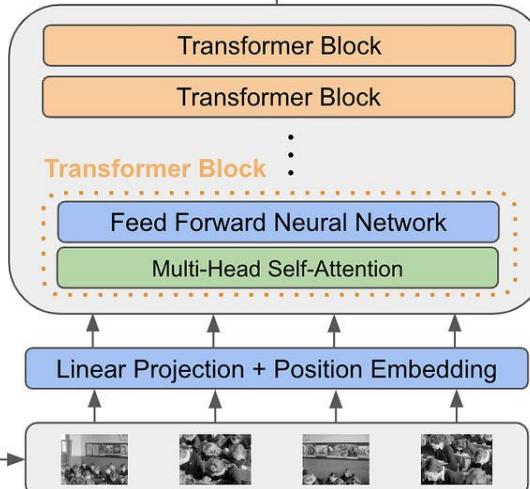


Deep Learning

Vision Transformer (ViT) Architecture



Generate Image Patches



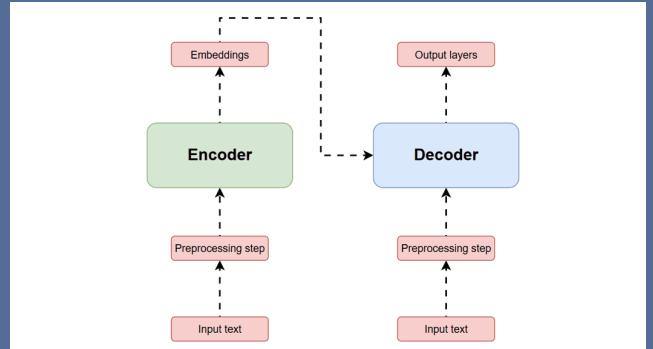
✓ Ventajas

- Capturan información global de la imagen, no solo local
- Son muy precisos en segmentación con imágenes grandes

✗ Desventajas

- Necesitan grandes cantidades de datos para entrenar bien
- Mayor consumo de memoria y cómputo en comparación con CNN

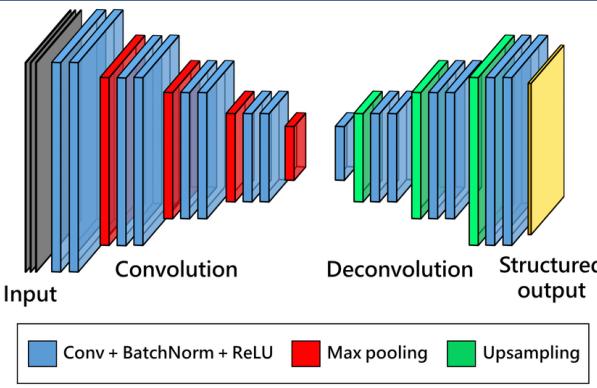
Transformers



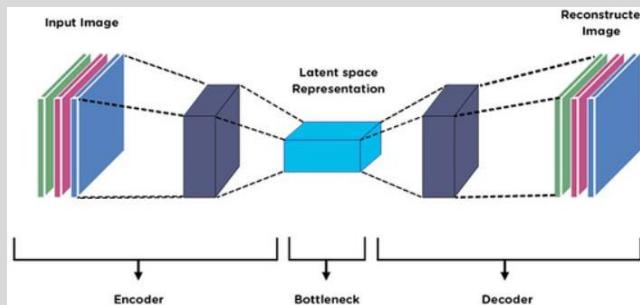
Los Transformers aplican el concepto de auto-atención, eliminando la dependencia exclusiva de las convoluciones. Han permitido modelar dependencias a larga distancia

Deep Learning

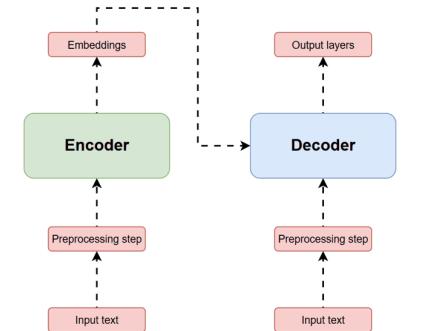
Fully Convolutional



Encoder-Decoder

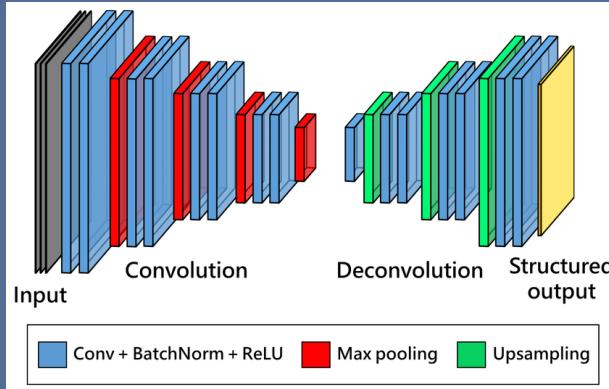


Transformers



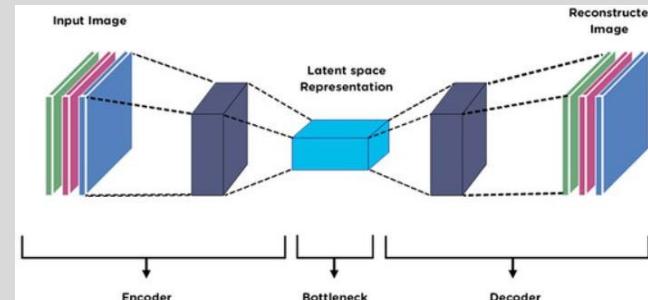
Deep Learning

Fully Convolutional



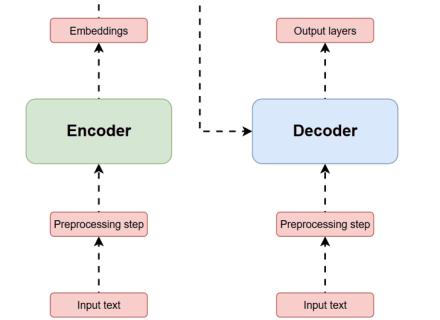
Ideal para segmentaciones rápidas con redes simples

Encoder-Decoder

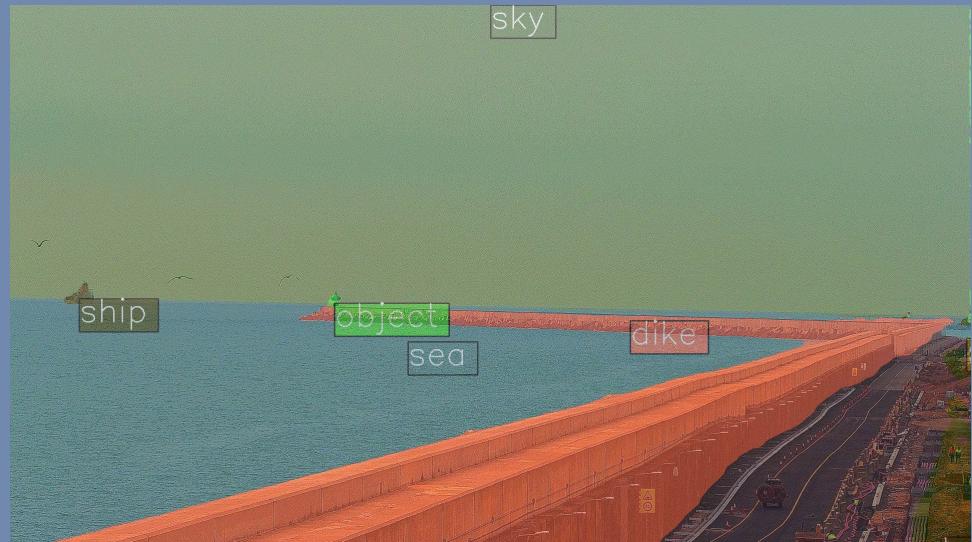


Ideal para segmentación precisa en imágenes médicas o con detalles finos

Transformers



Ideal para tareas avanzadas con imágenes grandes y disponibilidad de datos



03

¿Para que se utiliza
actualmente?

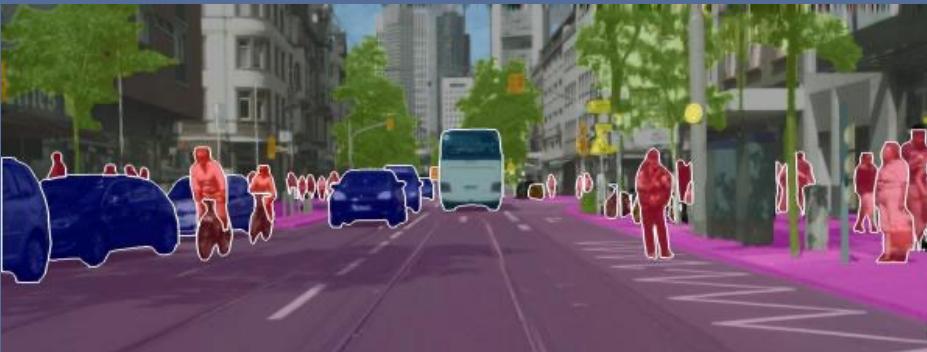
Mejora de imagen



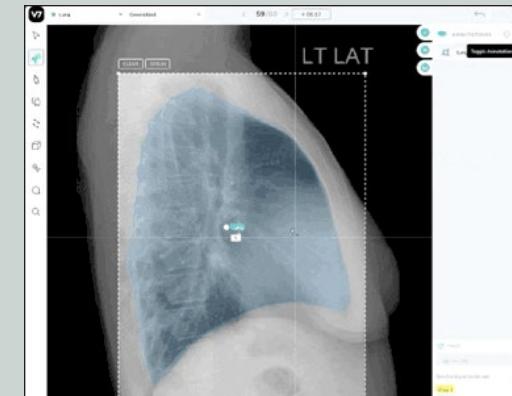
Análisis por satélite



Conducción autónoma



Apoyo al diagnóstico



Mejora de imagen



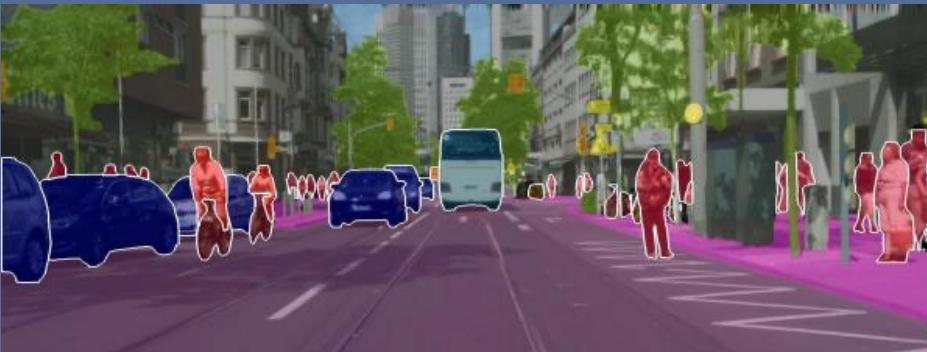
Mejora de imagen



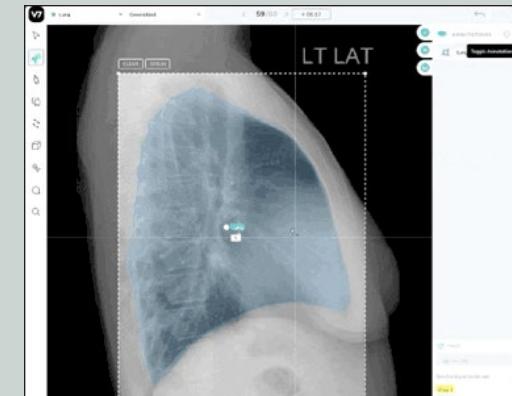
Análisis por satélite

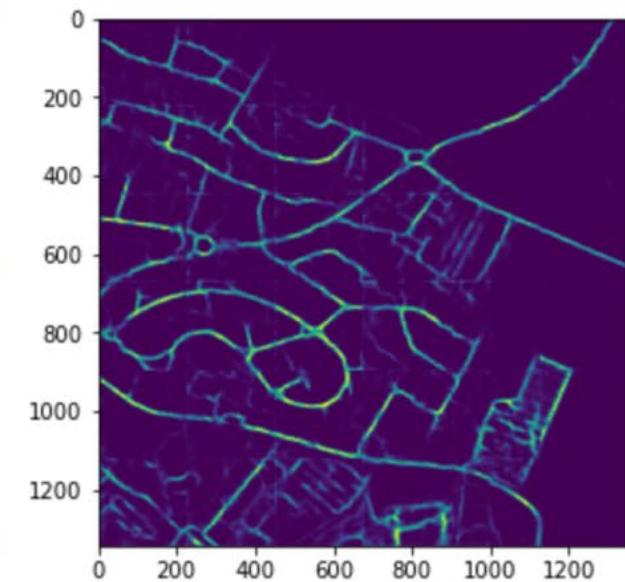
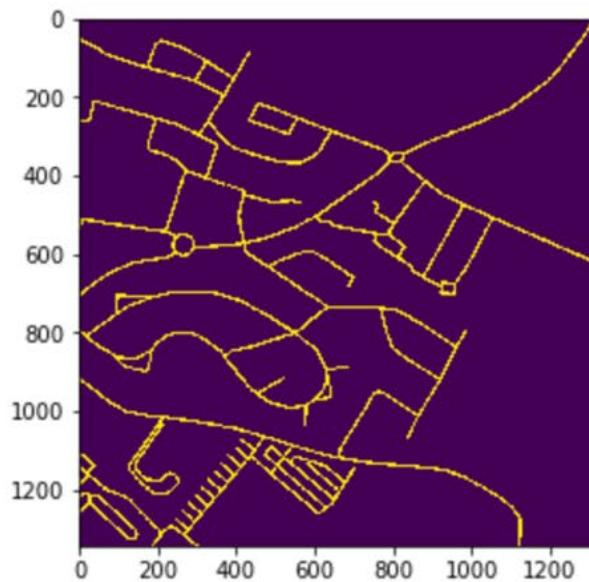
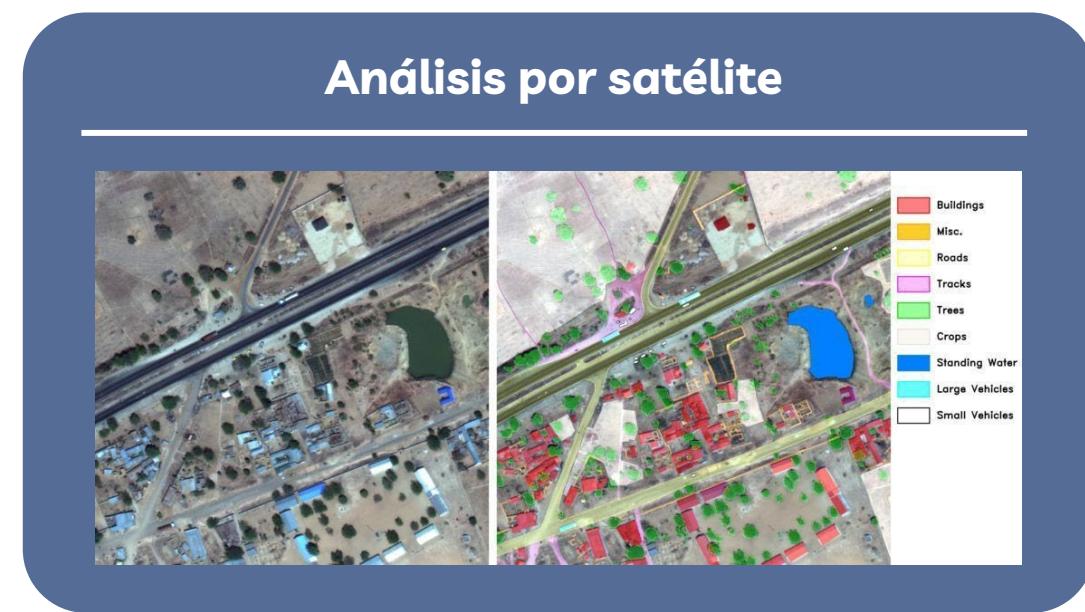
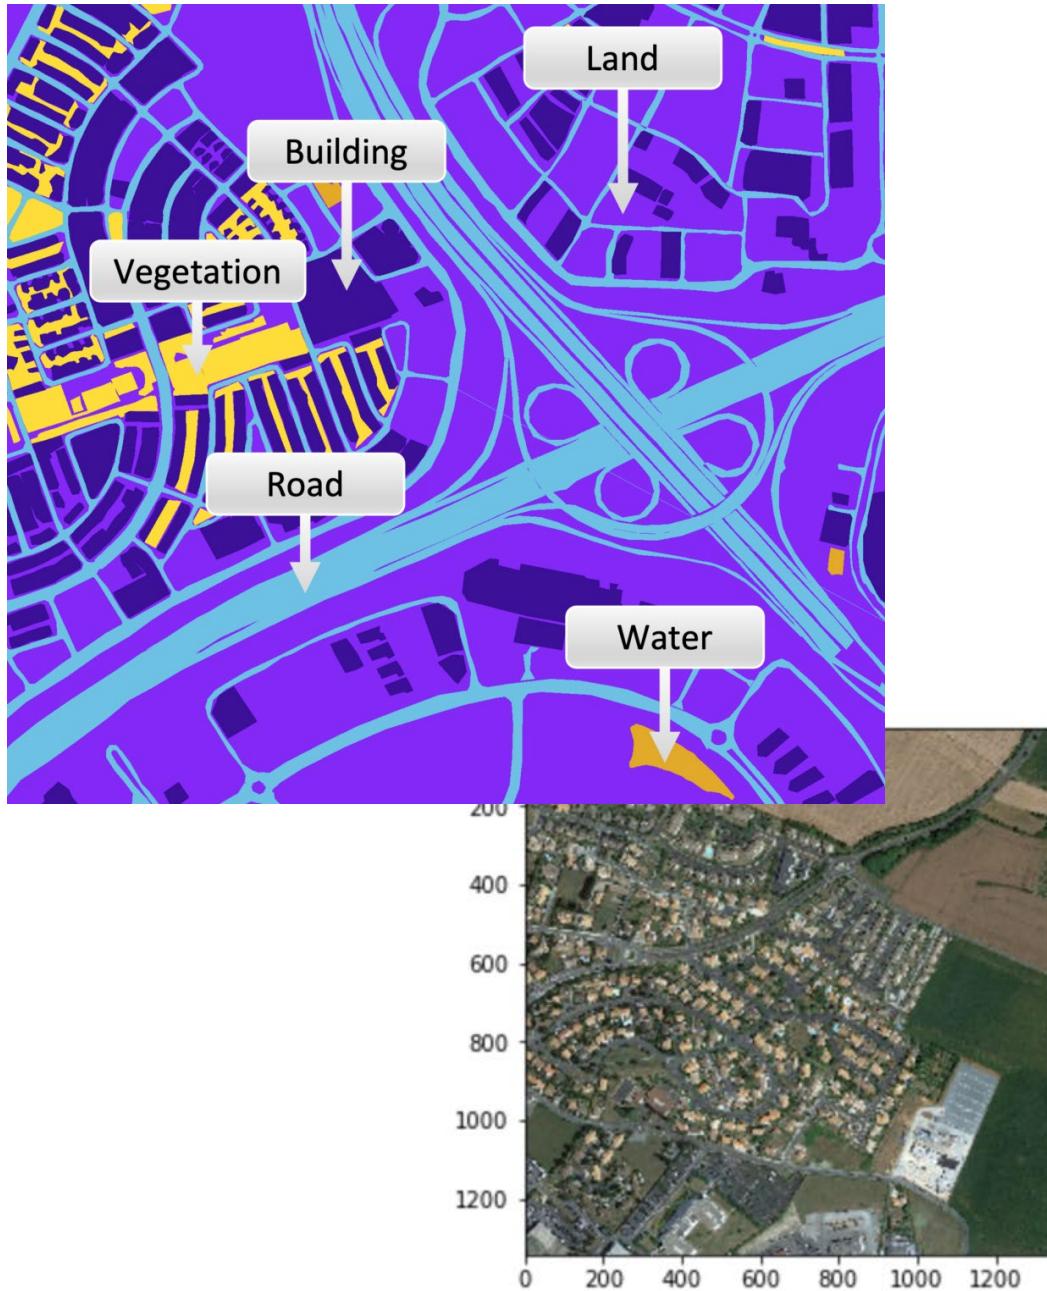


Conducción autónoma



Apoyo al diagnóstico





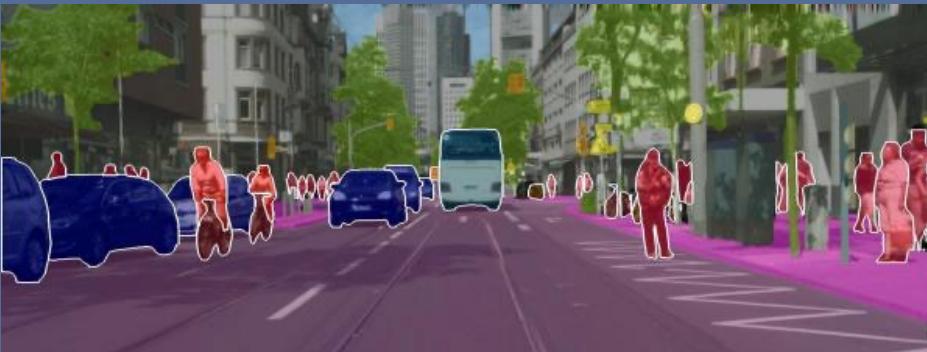
Mejora de imagen



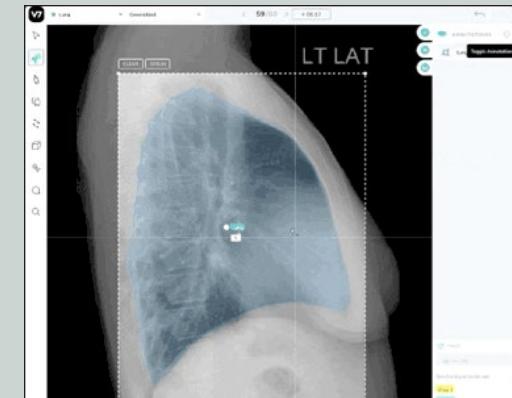
Análisis por satélite



Conducción autónoma



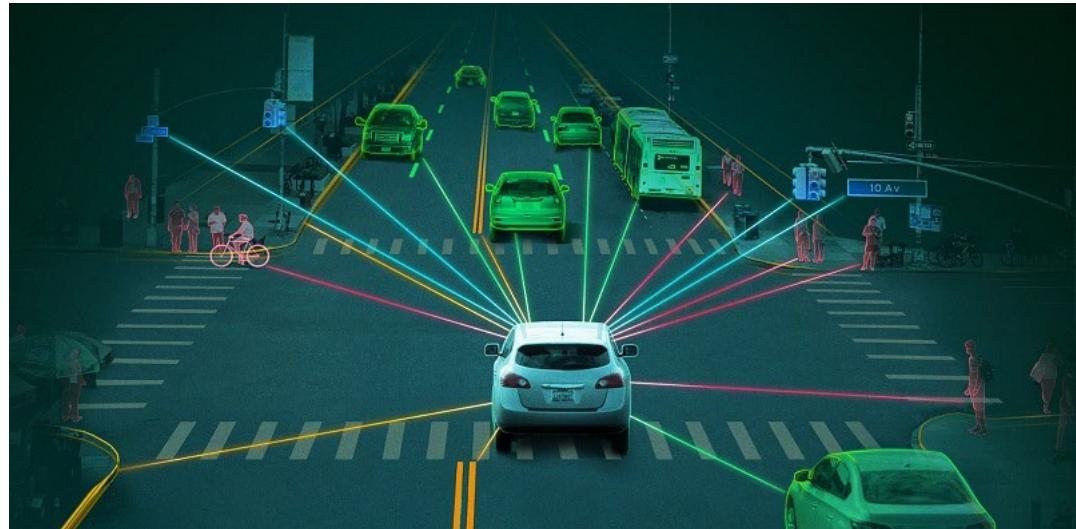
Apoyo al diagnóstico





Name	Colour	Name	Colour	Name	Colour	Name	Colour	Name	Colour	Name	Colour
road	Dark Purple	wall	Blue	traffic light	Orange	terrain	Light Green	rider	Red	bus	Dark Blue
sidewalk	Magenta	fence	Brown	traffic sign	Yellow	sky	Light Blue	car	Dark Blue	bicycle	Maroon
building	Grey	pole	Grey	vegetation	Green	person	Red	truck	Dark Blue	Dotted line	Cyan

Conducción autónoma



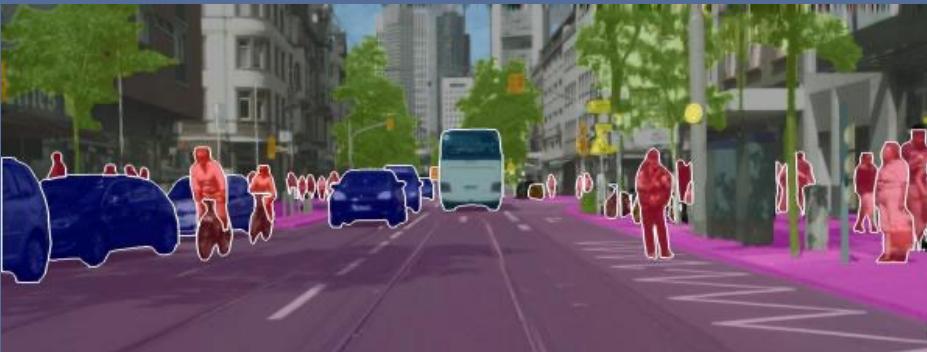
Mejora de imagen



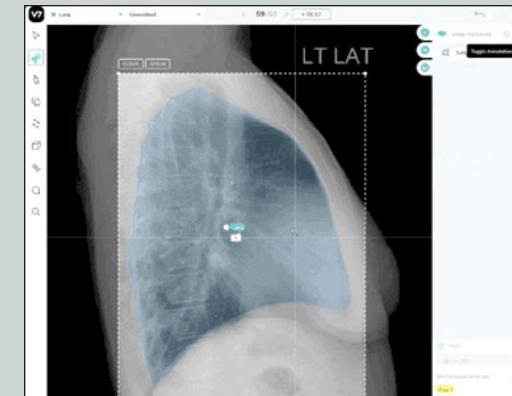
Análisis por satélite

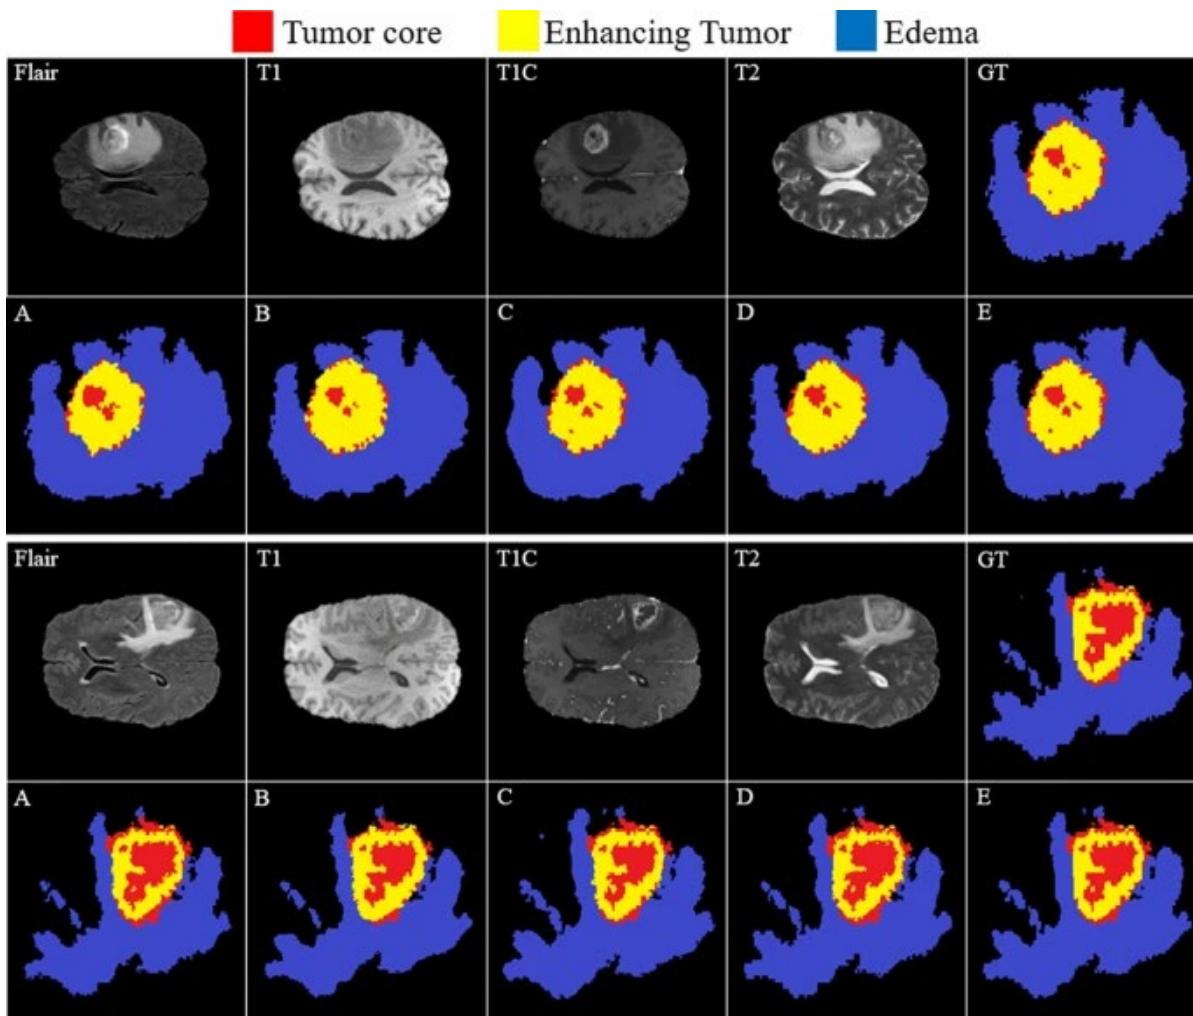


Conducción autónoma

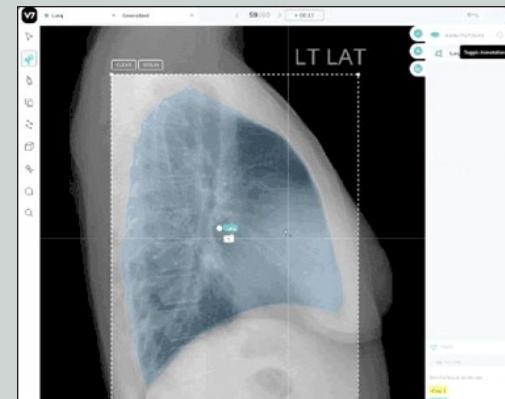


Apoyo al diagnóstico





Apoyo al diagnóstico



04

Investigación en curso

Dinámica costera



Longitud de marea



Cobertura de zonas terrestres

Perdida de zonas transitables

Posibles daños a embarcaciones



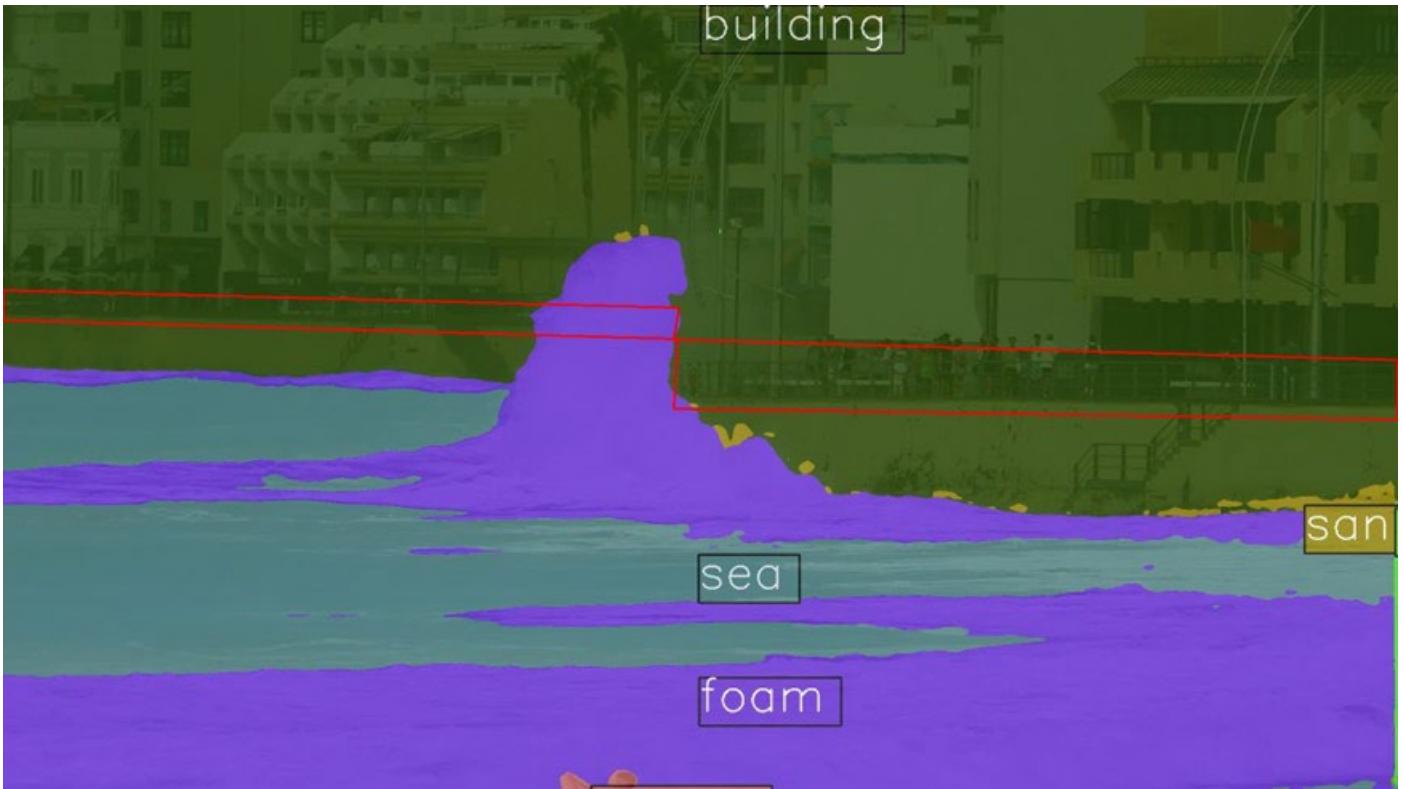


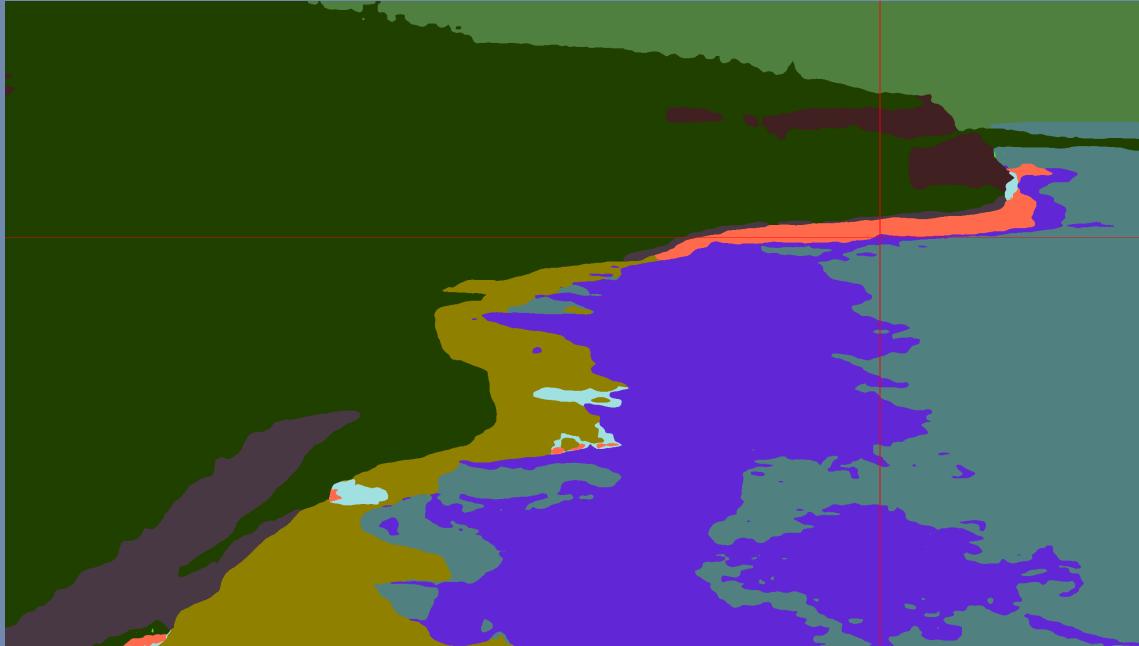
Detección de rebase

Seguridad en paseos marítimos

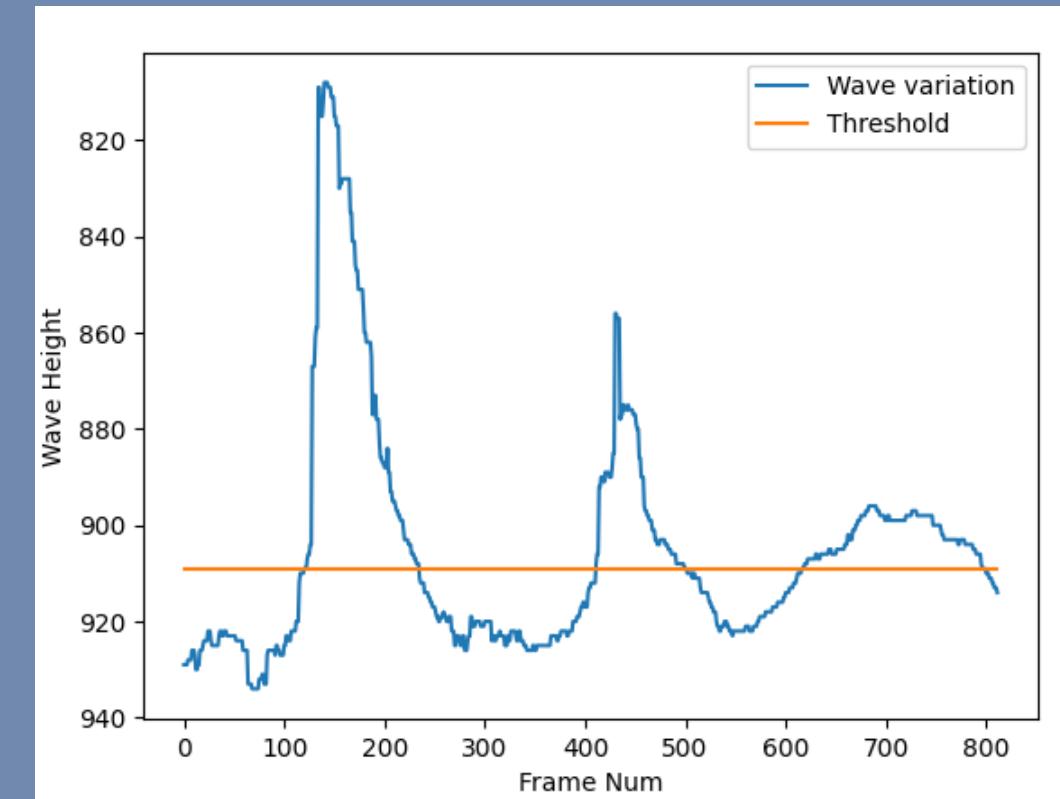
Control de estructuras críticas

Disponibilidad de zonas de baño





Cálculo del periodo

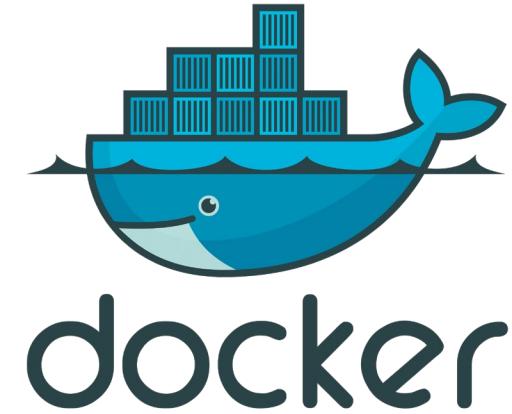
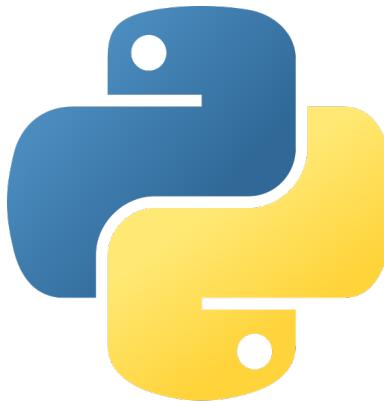


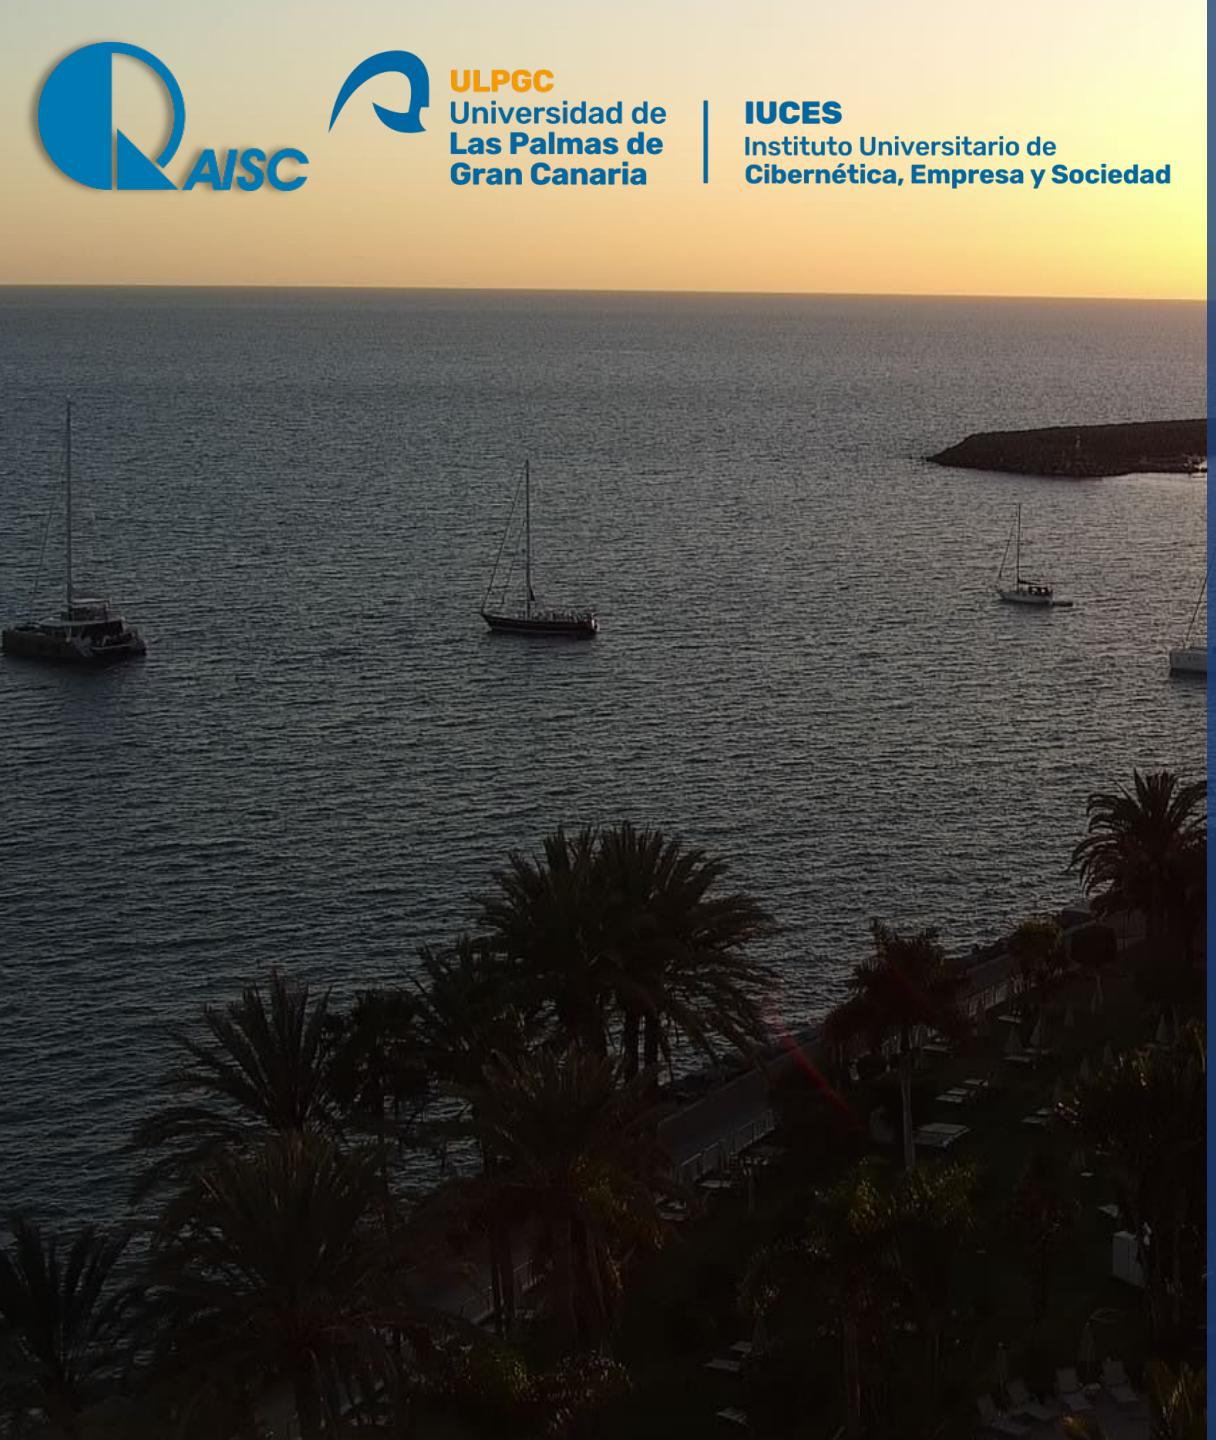
05

Ejemplos prácticos

Entorno de pruebas

https://github.com/reyesanfer/SemSeg_TestEnv.git





ULPGC
Universidad de
Las Palmas de
Gran Canaria

IUCES
Instituto Universitario de
Cibernetica, Empresa y Sociedad

**Gracias por
su atención**